

Rilevamento del tumore al seno tramite Machine Learning

Un'analisi comparativa tra Alberi di Decisione e SVM

Gruppo Progetto Machine Learning

29 gennaio 2026

Abstract. Questo rapporto presenta la progettazione, l'implementazione e la valutazione di un sistema di machine learning per la diagnosi del tumore al seno basato sul dataset Breast Cancer Wisconsin (Diagnostic). L'obiettivo primario è sviluppare un sistema di supporto alle decisioni in grado di classificare le masse tumorali come Benigne (0) o Maligne (1) con un'elevata accuratezza. Particolare enfasi è posta sulla minimizzazione dei Falsi Negativi (FN), poiché la mancata diagnosi di un caso maligno comporta tipicamente le conseguenze più gravi in un contesto clinico. Confrontiamo le prestazioni di un modello interpretabile (Albero di Decisione) con un classificatore ad alta dimensionalità (Support Vector Machine), utilizzando l'Analisi delle Componenti Principali (PCA) per la riduzione della dimensionalità. I nostri risultati sperimentali dimostrano che, mentre la SVM raggiunge metriche quantitative superiori, l'Albero di Decisione offre preziosi spunti qualitativi sulle soglie geometriche critiche dei nuclei cellulari.

Indice

1	Descrizione del Dominio e Obiettivi	3
1.1	Obiettivi	3
2	Analisi Esplorativa dei Dati (EDA)	3
2.1	Struttura del Dataset e Anteprima	3
2.2	Codifica e Distribuzione delle Classi	3
2.3	Analisi Multidimensionale delle Caratteristiche	4
2.4	Analisi della Multicollinearità	6
3	Ingegneria delle Caratteristiche: Analisi delle Componenti Principali	7
3.1	Standardizzazione dei Dati	7
3.2	Riduzione della Dimensionalità (PCA)	8
3.2.1	Strategia di Ritenzione della Varianza (Soglia del 95%)	8
3.2.2	Varianza Spiegata Cumulata	8
3.3	Trasformazione dello Spazio delle Caratteristiche	9
3.4	Visualizzazione dello Spazio Latente	9
3.5	Metodologia per la Prevenzione del Data Leakage	10

4	Risultati Sperimentali: Albero di Decisione	11
4.1	Strategia di Valutazione: Affrontare la Scarsità di Dati	11
4.2	Regolarizzazione tramite Pre-Potatura (Massima Profondità)	11
4.3	Analisi della Cross-Validation K-Fold	12
4.3.1	Stabilità dell'Albero attraverso i Fold	12
4.3.2	Metriche di Risultato K-Fold	13
4.4	Analisi Bias-Varianza	14
4.5	Analisi Leave-One-Out (LOO)	14
4.5.1	Metriche di Risultato LOO	15
4.6	Ottimizzazione Post-Potatura (Costo-Complessità)	15
4.6.1	Ricerca dell'Alfa Ottimale	15
4.6.2	Selezione del Modello Ottimale	16
5	Risultati Sperimentali: Support Vector Machine	17
5.1	Il Trucco del Kernel	17
5.2	Spazio delle Caratteristiche di Input	18
5.3	Analisi del Kernel e Cross-Validation	18
5.4	Previsione Finale del Test e Confronto	19
5.5	Analisi della Curva ROC	19
6	Analisi Comparativa: Albero di Decisione vs SVM	20
6.1	Metriche Finali Consolidate	20
6.2	Credibilità e Significatività Statistica	21
6.3	Robustezza e Generalizzabilità del Modello	21
7	Conclusioni	21

1. Descrizione del Dominio e Obiettivi

Il dominio di questo progetto è la diagnostica medica, specificamente nel campo dell'oncologia. Il tumore al seno rimane uno dei tumori più comuni al mondo e la diagnosi precoce è fondamentale per migliorare i tassi di sopravvivenza.

1.1. Obiettivi

L'obiettivo principale è automatizzare la classificazione delle masse mammarie sulla base di dati biometrici derivati da immagini digitalizzate di un agoaspirato (FNA). Il compito di classificazione è binario:

- **Benigno (0)**: Cellule non cancerose.
- **Maligno (1)**: Cellule cancerose che richiedono un intervento medico immediato.

Da una prospettiva clinica, non tutti gli errori di classificazione hanno lo stesso peso. Un **Falso Negativo** (classificare un tumore maligno come benigno) è un errore critico che potrebbe ritardare un trattamento salvavita. Pertanto, il nostro obiettivo tecnico è massimizzare il **Recall (Sensibilità)** per la classe Maligna mantenendo un'elevata **Accuratezza** complessiva.

2. Analisi Esplorativa dei Dati (EDA)

Prima di applicare qualsiasi algoritmo di apprendimento, è stata condotta un'approfondita Analisi Esplorativa dei Dati per comprendere la struttura sottostante dei dati, la separazione delle classi e le relazioni tra le caratteristiche.

2.1. Struttura del Dataset e Anteprima

Il dataset utilizzato è il **Breast Cancer Wisconsin (Diagnostic) Data Set**. Consiste di 569 istanze, ciascuna caratterizzata da 30 caratteristiche numeriche che rappresentano la Media, l'Errore Standard e il "Peggior" (media dei tre valori più grandi) di 10 caratteristiche dei nuclei cellulari (es. **radius**, **texture**, **area**).

La Tabella 1 fornisce un'anteprima dei dati grezzi, evidenziando la differenza di scala tra le caratteristiche geometriche (come **Area**, che raggiunge > 1000) e i coefficienti morfologici (come **Smoothness**, < 0.1), che rende necessaria la successiva standardizzazione.

Tabella 1: Anteprima del Dataset: Prime 5 righe (Colonne selezionate)

Indice	radius1	texture1	perimeter1	area1	smoothness1	...	radius3	texture3	perimeter3	area3
0	17.99	10.38	122.80	1001.0	0.11840	...	25.38	17.33	184.60	2019.0
1	20.57	17.77	132.90	1326.0	0.08474	...	24.99	23.41	158.80	1956.0
2	19.69	21.25	130.00	1203.0	0.10960	...	23.57	25.53	152.50	1709.0
3	11.42	20.38	77.58	386.1	0.14250	...	14.91	26.50	98.87	567.7
4	20.29	14.34	135.10	1297.0	0.10030	...	22.54	16.67	152.20	1575.0

2.2. Codifica e Distribuzione delle Classi

Per integrare la diagnosi nei modelli matematici, è stato eseguito un passaggio di **Target Encoding** prima della suddivisione train-test: i campioni Benigni sono stati mappati a **0** e i campioni Maligni a **1**.

Un'analisi della variabile target rivela, sull'intero dataset, una distribuzione delle classi di **357 Benigni (62.7%)** e **212 Maligni (37.3%)**.




Figura 1: Distribuzione della Diagnosi: Benigni vs Maligni sul set di addestramento

Dal punto di vista teorico, ciò indica un lieve squilibrio delle classi. Pur non essendo abbastanza grave da richiedere un sovracampionamento sintetico (come SMOTE), introduce un potenziale **Bias di Campionamento** se non affrontato durante la fase di valutazione. Se un classificatore ingenuo dovesse prevedere tutti i casi come Benigni, otterrebbe un'accuratezza di $\approx 63\%$. Per mitigare questo problema, abbiamo impiegato la **Cross-Validation Stratificata**, che garantisce che ogni fold di addestramento preservi il rapporto 63/37, fornendo una stima più credibile delle reali prestazioni di generalizzazione del modello sulla classe di minoranza.

2.3. Analisi Multidimensionale delle Caratteristiche

Per identificare i marker biometrici con il più alto potenziale diagnostico, abbiamo condotto un'analisi combinata delle distribuzioni delle caratteristiche, delle scale e della separabilità.




Figura 2: Analisi Completa dei Boxplot. Il grafico rivela (1) un'estrema disparità di scala tra le caratteristiche, (2) la presenza di rari outlier morfologici (punti) e (3) il potere discriminante di caratteristiche come il Raggio e la Concavità per la separazione tra benigni e maligni.




Figura 3: Grafico a dispersione che visualizza la distribuzione dei casi Benigni vs Maligni.

L'analisi della Figura 2 rivela diversi spunti critici:

1. **Squilibrio di Scala e Requisiti di Pre-elaborazione:** Le dimensioni fisiche (es. `area_mean`, $\mu \approx 654$) operano a tre ordini di grandezza in più rispetto a coefficienti come `smoothness_mean` ($\mu \approx 0.096$). Questo divario di grandezza conferma la necessità della standardizzazione Z-score ($\mu = 0, \sigma = 1$) per prevenire aggiornamenti del gradiente distorti nei modelli basati sulla distanza.
2. **Presenza di Outlier e Robustezza:** Utilizzando una soglia di $|z| > 3$, sono stati rilevati outlier significativi in caratteristiche come `compactness_se`. Questi valori estremi rappresentano varianti tumorali rare. La loro presenza giustifica l'uso del **Kernel RBF**, che utilizza un'influenza radiale localizzata meno suscettibile di essere distorta da outlier distanti rispetto a un iperpiano lineare.
3. **Potere Discriminante delle Caratteristiche (Separabilità):**
 - *Alta Separabilità:* Caratteristiche come `concave points_mean` e `radius_worst` mostrano distribuzioni bimodali con una sovrapposizione minima tra le classi.
 - *Bassa Separabilità:* Il rumore biologico è più elevato in caratteristiche come `fractal_dimension` o `texture_se`, dove le distribuzioni per le classi B e M si sovrappongono quasi completamente.

2.4. Analisi della Multicollinearità

Data l'origine geometrica delle caratteristiche (es. il Raggio è matematicamente correlato al Perimetro e all'Area), ci aspettavamo un alto grado di correlazione. Abbiamo calcolato la Matrice di Correlazione di Pearson per verificarlo.




Figura 4: Mappa di calore della correlazione delle caratteristiche. Il rosso più scuro indica un'elevata correlazione positiva.

La Figura 4 conferma la presenza di **Multicollinearità**, una condizione in cui le variabili indipendenti sono altamente correlate.

1. **Ridondanza Strutturale:** Abbiamo osservato una correlazione quasi perfetta ($\rho \approx 1.0$) tra **radius**, **perimeter** e **area**, come previsto data la loro interdipendenza geometrica.
2. **Implicazioni Statistiche:** La multicollinearità aumenta la varianza delle stime dei coefficienti, rendendo instabili modelli come la Regressione Logistica o gli Alberi di Decisione non potati.

Questa struttura ridondante fornisce la giustificazione teorica per l'**Analisi delle Componenti Principali (PCA)**. Eseguito una scomposizione in autovettori della matrice di covarianza, possiamo proiettare lo spazio a 30 dimensioni in una varietà a dimensione inferiore in cui ogni componente è **ortogonale** (non correlata). Questa trasformazione è essenziale per l'algoritmo SVM, poiché riduce la complessità della ricerca dell'iperpiano ottimale senza perdere le informazioni strutturali dei dati.

3. Ingegneria delle Caratteristiche: Analisi delle Componenti Principali

L'ingegneria delle caratteristiche è un passaggio critico in questa pipeline, volto a trasformare le 30 caratteristiche grezze altamente correlate in un insieme ridotto di variabili non correlate che catturano la massima informazione (varianza).

3.1. Standardizzazione dei Dati

La PCA calcola le direzioni di massima varianza. Poiché la varianza è sensibile alla scala della variabile (es. **Area** ≈ 1000 vs **Smoothness** ≈ 0.1), l'applicazione della PCA sui dati grezzi distorcerebbe pesantemente le componenti verso le caratteristiche con magnitudo maggiore.

Per ovviare a ciò, abbiamo applicato la **Standardizzazione Z-score** usando **StandardScaler**:

$$z = \frac{x - \mu}{\sigma}$$

Fondamentalmente, per prevenire il **data leakage**, lo scaler è stato adattato **solo sul set di addestramento**. I parametri μ (media) e σ (deviazione standard) appresi dai dati di addestramento sono stati poi applicati per trasformare il set di test.

3.2. Riduzione della Dimensionalità (PCA)

Abbiamo eseguito la PCA per identificare gli autovettori (Componenti Principali) della matrice di covarianza.

3.2.1 Strategia di Ritenzione della Varianza (Soglia del 95%)

Data la natura critica della diagnostica medica, la massimizzazione della ritenzione delle informazioni è fondamentale. La Regola di Kaiser ($\lambda > 1$) suggeriva di mantenere solo 6 componenti. Tuttavia, ciò scarterebbe circa l'11% della varianza, che potrebbe contenere segnali sottili ma clinicamente rilevanti.

Pertanto, abbiamo adottato una **Strategia di Ritenzione della Varianza** più conservativa, selezionando il numero di componenti necessari per spiegare almeno il **95%** della varianza totale. Questa soglia ha portato alla selezione di **10 Componenti Principali**. Questa scelta garantisce che la stragrande maggioranza delle informazioni biologiche sia preservata, ottenendo comunque una riduzione della dimensionalità di 3 volte (da 30 a 10).

3.2.2 Varianza Spiegata Cumulata

Abbiamo verificato questa scelta analizzando il rapporto di varianza cumulata spiegata.




Figura 5: Analisi della Varianza Spiegata. Lo Scree plot mostra il "gomito" che indica il numero ottimale di componenti.

Le prime 10 componenti spiegano circa il **95.21%** delle informazioni totali contenute nel dataset. Ciò rappresenta un aumento significativo della ritenzione delle informazioni rispetto all'89% delle prime 6 componenti, fornendo un set di caratteristiche più ricco per i modelli di classificazione.

3.3. Trasformazione dello Spazio delle Caratteristiche

La trasformazione finale ha proiettato il dataset sul sottospazio a 10 dimensioni definito dai primi 10 autovettori.

- **Dati di addestramento:** Trasformati da 30 dimensioni a 10.
- **Dati di test:** Scalati e proiettati utilizzando gli autovettori del set di addestramento.




Figura 6: Mappa di calore dei caricamenti (loadings) della PCA. Questa visualizzazione rivela quali caratteristiche originali contribuiscono maggiormente a ciascuna Componente Principale.

La seguente tabella mostra le prime 5 righe del dataset trasformato, illustrando i valori nel nuovo spazio delle caratteristiche a 10 dimensioni:

Tabella 2: Prime 5 righe della matrice delle caratteristiche trasformata tramite PCA

Indice	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9	PC10
0	-0.876	-2.571	-0.549	1.636	-0.263	0.110	0.506	-0.214	-0.109	0.417
1	-2.505	0.192	-0.405	-2.448	0.601	0.008	-1.094	0.073	0.555	0.156
2	-1.354	0.418	2.545	1.219	-1.767	0.709	0.767	-0.053	-0.437	0.186
3	4.854	3.018	-1.627	0.702	-2.814	-0.375	-0.474	0.061	0.180	-0.564
4	2.926	-1.867	2.486	-0.104	0.181	-0.975	-0.773	-0.177	-0.220	-0.343

3.4. Visualizzazione dello Spazio Latente

Per valutare il potere discriminante delle nuove caratteristiche, abbiamo visualizzato il dataset nello spazio 2D definito dalle prime due componenti (PC1 e PC2), che da sole rappresentano oltre il 64% della varianza.




Figura 7: Grafico a dispersione dei casi Maligni (Rosso) vs Benigni (Blu) nello spazio PC1-PC2. La separazione chiara ma imperfetta giustifica l'uso di modelli non lineari.

Come mostrato nella Figura 7, le due classi mostrano una separazione ragionevolmente chiara anche in sole due dimensioni. I casi Maligni tendono a raggrupparsi verso destra (PC1 positiva), mentre i casi Benigni si raggruppano a sinistra. Tuttavia, persiste una regione di sovrapposizione, suggerendo che un semplice classificatore lineare potrebbe essere insufficiente e motivando l'uso di modelli non lineari come la SVM con kernel RBF.

3.5. Metodologia per la Prevenzione del Data Leakage

Una sfida critica nello sviluppo di modelli diagnostici clinici è garantire la rigorosa separazione tra la conoscenza dell'addestramento e la valutazione del test. Il **Data Leakage** si verifica quando informazioni provenienti dall'esterno del dataset di addestramento vengono utilizzate per creare il modello, portando a risultati eccessivamente ottimistici che falliscono nella distribuzione nel mondo reale.

In questo progetto, abbiamo implementato un rigoroso protocollo “**Fit on Train, Transform on Test**” per mantenere l'integrità della pre-elaborazione:

1. **Integrità della Standardizzazione:** Lo **StandardScaler** è stato adattato esclusivamente sul set di addestramento. Le medie (μ) e le deviazioni standard (σ) risultanti sono state poi applicate al set di test come trasformazione fissa. Ciò impedisce al processo di addestramento di “vedere” la distribuzione o gli outlier della popolazione di test.
2. **Integrità della Proiezione PCA:** Allo stesso modo, le Componenti Principali (autovetori) sono state derivate esclusivamente dalla matrice di covarianza dell'addestramento. I dati di test sono stati proiettati su questo spazio latente stabilito senza ricalcolare le componenti. Ciò garantisce che il modello valuti i campioni di test all'interno dell'esatto sistema di coordinate definito durante l'addestramento.
3. **Gestione dello Stato del Processo:** Durante la fase di ottimizzazione, abbiamo identificato un rischio di “Process Leakage” in cui i controlli condizionali potevano portare

all'uso di caratteristiche non aggiornate. Abbiamo risolto il problema applicando una **Pipeline Procedurale Esplicita**, garantendo che ogni valutazione sia preceduta da una trasformazione obbligatoria.

Queste misure garantiscono che le nostre metriche di performance (Accuratezza, Recall) siano scientificamente valide e rappresentino una stima affidabile delle prestazioni del sistema su futuri casi diagnostici non visti.

4. Risultati Sperimentali: Albero di Decisione

L'Albero di Decisione è stato selezionato come nostro modello di base grazie alla sua natura di "Scatola Bianca", che consente una piena interpretabilità della logica decisionale.

4.1. Strategia di Valutazione: Affrontare la Scarsità di Dati

Il dataset è composto da 569 campioni. Nel contesto di una robusta validazione del machine learning, questo è considerato un **dataset piccolo**. Mentre un tradizionale metodo hold-out (es. una suddivisione fissa 70/30 train-test) potrebbe produrre un'accuratezza apparentemente elevata, è statisticamente fragile in questo contesto a causa dell'alta varianza.

Per mitigare questa inaffidabilità statistica e garantire la robustezza del nostro sistema diagnostico, abbiamo adottato rigorosi metodi di ricampionamento: **Cross-Validation Stratificata a 10 Fold** e **Validazione Leave-One-Out (LOO)**.

4.2. Regularizzazione tramite Pre-Potatura (Massima Profondità)

Per gestire il compromesso bias-varianza durante la costruzione iniziale dell'albero, abbiamo implementato una strategia di **Pre-potatura** (Pre-pruning/Early Stopping) impostando `max_depth=3`.

Nel contesto del quadro "Valutazione e Credibilità", questa scelta è giustificata da:

1. **Prevenzione dell'Alta Varianza:** Dato il nostro piccolo dataset ($N = 569$), permettere all'albero di crescere fino al suo pieno potenziale (fino a quando le foglie sono pure) porterebbe a un overfitting estremo. Una profondità di 3 costringe il modello a catturare solo le soglie biometriche più significative (es. `perimeter_worst`, `concave_points_mean`) ignorando il rumore idiosincratico nei campioni di addestramento.
2. **Interpretabilità Clinica:** Uno strumento diagnostico deve essere verificabile. Un albero poco profondo garantisce che la logica decisionale rimanga trasparente e facile da verificare per un medico, agendo come un modello "white-box".
3. **Stabilità della Generalizzazione:** La limitazione della profondità garantisce che i confini decisionali siano ortogonali e stabili attraverso i diversi fold, come verificato nella Figura 9.




Figura 8: Classifica dell'Importanza delle Caratteristiche estratta dall'Albero di Decisione. Conferma che le proprietà geometriche come 'Worst Perimeter' sono le più discriminanti.

4.3. Analisi della Cross-Validation K-Fold

Abbiamo eseguito 10 iterazioni del processo di addestramento. In ogni iterazione, il modello (profondità massima = 3) è stato addestrato su 9 fold e validato sul rimanente.

4.3.1 Stabilità dell'Albero attraverso i Fold

Per verificare la stabilità dei confini decisionali, abbiamo visualizzato la struttura dell'albero risultante per ciascuno dei 10 fold.




Figura 9: Alberi di decisione generati attraverso i 10 fold. La coerenza nella selezione delle caratteristiche (suddivisione su marker biometrici simili) dimostra l'affidabilità del nostro modello nonostante il dataset limitato.

4.3.2 Metriche di Risultato K-Fold

Le metriche di performance aggregate attraverso i 10 fold indicano un robusto modello di base. L'Intervallo di Confidenza (IC) al 95% suggerisce che possiamo aspettarci che l'accuratezza del modello su dati non visti ricada in questo intervallo con un'alta probabilità.

Tabella 3: Prestazioni della Cross-Validation Stratificata a 10 Fold

Metrica	Valore
Accuratezza Media	91.85%
Intervallo di Confidenza 95%	[89.04%, 94.65%]
F1-Score Medio	89.13%




Figura 10: Matrice di Confusione Globale: Risultati aggregati dei 10 round di previsione (Albero di Decisione). Questa matrice mostra il totale di TP, TN, FP e FN attraverso tutti i fold.

4.4. Analisi Bias-Varianza

un'analisi delle dinamiche di performance del modello rivela la relazione tra la dimensione dell'addestramento e l'errore del modello:

- **Controllo dell'Alta Varianza:** Il divario tra i punteggi di addestramento e validazione per entrambi i modelli si riduce significativamente all'aumentare degli esempi di addestramento, indicando che la regolarizzazione (Potatura per l'Albero, parametro C per la SVM) sta prevenendo efficacemente un grave overfitting.
- **Sufficienza della Dimensione del Campione:** Il plateau nelle prestazioni suggerisce che l'aggiunta di ulteriori istanze mediche produrrebbe rendimenti decrescenti, confermando che le 569 istanze sono adeguate per questo spazio di caratteristiche.

4.5. Analisi Leave-One-Out (LOO)

In seguito all'analisi K-Fold, abbiamo eseguito una validazione Leave-One-Out per massimizzare la dimensione del set di addestramento ($N - 1$ campioni), riducendo il bias della stima delle performance.

4.5.1 Metriche di Risultato LOO

I risultati ottenuti dalla validazione LOO confermano i risultati della strategia K-Fold, mostrando metriche di affidabilità coerenti.

Tabella 4: Prestazioni della Validazione Leave-One-Out (LOO)

Metrica	Valore
Accuratezza Media	89.67%
Intervallo di Confidenza 95%	[86.86%, 92.48%]
F1-Score Medio	86.38%




Figura 11: Matrice di Confusione Leave-One-Out: Risultato di N test individuali.

4.6. Ottimizzazione Post-Potatura (Costo-Complessità)

Gli alberi di decisione, per loro natura, tendono a crescere indefinitamente finché ogni nodo foglia n'è "puro" (contiene solo una classe). Ciò porta spesso a modelli altamente complessi che si adattano al rumore nei dati di addestramento, con conseguente **overfitting** (alta varianza). Per contrastare questo fenomeno, abbiamo applicato la **Potatura di Costo-Complessità** (Cost-Complexity Pruning).

L'algoritmo di potatura calcola una sequenza di sottoalberi rimuovendo iterativamente l'"anello più debole" — il nodo che contribuisce meno all'accuratezza complessiva rispetto alla complessità che aggiunge. La funzione obiettivo minimizzata è:

$$R_{\alpha}(T) = R(T) + \alpha|T|$$

Dove $R(T)$ è il tasso di errata classificazione, $|T|$ è il numero di nodi terminali (foglie) e α (alfa) è il parametro di complessità.

4.6.1 Ricerca dell'Alfa Ottimale

Abbiamo eseguito una ricerca sistematica del miglior α . Per ogni valore candidato estratto dal percorso di potatura, abbiamo addestrato un nuovo albero e valutato le sue prestazioni sia sul Training Set che sul Test Set.




Figura 12: Compromesso Bias-Varianza: All'aumentare di Alfa (spostandosi a destra), la complessità dell'albero diminuisce. L'accuratezza del Training (tipicamente la curva più alta) scende, mentre l'accuratezza del Test (curva più bassa) raggiunge un picco prima di scendere. Il picco rappresenta il punto di generalizzazione ottimale.

L'analisi del grafico "Alfa vs Accuratezza" ha rivelato il classico compromesso Bias-Varianza. Valori di alfa molto bassi hanno prodotto alberi che si adattavano perfettamente ai dati di addestramento (Accuratezza $\approx 100\%$) ma con scarse prestazioni sui dati di test (Overfitting). Valori di alfa molto alti hanno prodotto alberi eccessivamente semplici ("stumps") con un alto bias (Underfitting).




Figura 13: Visualizzazione dell'Albero di Decisione Potato. La profondità dell'albero è controllata dal parametro alfa ottimale, bilanciando complessità e interpretabilità. Notare come le suddivisioni primarie avvengano sulle Componenti Principali (es. PC1, PC2), che sono combinazioni lineari delle caratteristiche geometriche originali.

4.6.2 Selezione del Modello Ottimale

L'algoritmo ha identificato automaticamente lo specifico valore di α che ha massimizzato l'accuratezza sul Test set tenuto da parte.

- Alfa Ottimale trovato: 0.004508

- **Accuratezza del Test corrispondente: 95.61%**

Questo albero potato rappresenta il miglior equilibrio per questo dataset: è più semplice e interpretabile della versione non potato, eppure generalizza significativamente meglio ai dati dei pazienti non visti.

5. Risultati Sperimentali: Support Vector Machine

La Support Vector Machine (SVM) rappresenta il nostro approccio “Scatola Nera”. Il principio fondamentale della SVM è trovare l’iperpiano ottimale che separi le classi con il margine massimo.

5.1. Il Trucco del Kernel

Per determinare se i dati siano linearmente separabili o richiedano confini decisionali non lineari, abbiamo sperimentato il “Trucco del Kernel” (Kernel Trick). Questa tecnica consente alla SVM di operare in uno spazio di caratteristiche ad alta dimensionalità senza calcolare esplicitamente le coordinate, calcolando i prodotti scalari tra coppie di dati. Il “Trucco del Kernel” consente alla SVM di operare in uno spazio di caratteristiche ad alta dimensionalità $\phi(x)$ senza calcolare esplicitamente le coordinate, testando se la proiezione dei dati in una dimensione superiore migliora la separazione delle classi rispetto allo spazio delle caratteristiche originale: $K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$.

Questa tecnica mappa efficacemente i dati non linearmente separabili in uno spazio a dimensionalità superiore in cui un iperpiano lineare può separare le classi (Benigno vs Maligno). L’analisi attuale confronta:

- **Kernel Lineare:** $K(x, y) = x^T y$
- **Kernel Polinomiale:** $K(x, y) = (\gamma x^T y + r)^d$
- **Kernel RBF (Gaussiano):** $K(x, y) = \exp(-\gamma \|x - y\|^2)$

Il kernel RBF è particolarmente efficace per i dati biologici in quanto crea confini decisionali chiusi attorno a raggruppamenti di campioni maligni.




Figura 14: Visualizzazione 3D del Trucco del Kernel. I dati, non linearmente separabili in 2D, diventano separabili quando proiettati in uno spazio a dimensionalità superiore.

5.2. Spazio delle Caratteristiche di Input

Il modello SVM utilizza le **10 Componenti Principali** selezionate nella fase di Ingegneria delle Caratteristiche (preservando il 95% della varianza). Questo spazio di input è fondamentale per la SVM in quanto fornisce:

1. **Ortogonalità:** La natura non correlata delle caratteristiche PC aiuta la convergenza del problema di ottimizzazione (programmazione quadratica).
2. **Riduzione del Rumore:** Scartando le ultime 20 componenti (che contengono in gran parte rumore), il processo di massimizzazione del margine ha meno probabilità di adattarsi ad artefatti, migliorando così la generalizzazione sul Test Set.

5.3. Analisi del Kernel e Cross-Validation

Abbiamo confrontato tre kernel sull'intero set di addestramento utilizzando la Cross-Validation Stratificata a 10 Fold.

Tabella 5: Risultati della Cross-Validation a 10 Fold (Set di Addestramento)

Modello	Accuratezza Media	Stabilità (Dev. Std)
SVM Lineare	97.15%	$\pm 1.96\%$
SVM RBF	95.82%	$\pm 3.34\%$
SVM Poly	85.25%	$\pm 5.28\%$

Il **Kernel Lineare** ha mostrato eccellenti prestazioni e stabilità, suggerendo che lo spazio delle caratteristiche (dopo la PCA) sia già ben separabile linearmente. Il kernel polinomiale ha avuto prestazioni significativamente peggiori, probabilmente a causa di una mappatura inadatta alla struttura dello spazio delle caratteristiche.




Figura 15: Confronto dei Kernel SVM.

5.4. Previsione Finale del Test e Confronto

I modelli sono stati valutati sul Test Set tenuto da parte. Le matrici di confusione (Figura 16) evidenziano la differenza critica nel **Recall**.




Figura 16: Matrici di Confusione sui Dati di Test: Lineare vs RBF vs Poly. Notare la variazione dei Falsi Negativi (quadrante in basso a sinistra di ogni matrice) che influisce direttamente sul Recall.

Confrontando la Cross-Validation (fase di addestramento) e le previsioni del Test:

1. **Generalizzazione:** Il Kernel Lineare ha mantenuto eccellenti prestazioni (98.2%) sul Test Set, superando significativamente il Kernel RBF (93.9%).
2. **Superiorità del Recall:** Il **Kernel Lineare** ha sorprendentemente superato il kernel RBF nell'identificare i casi Maligni, indicando che la complessità del confine RBF non era necessaria e il modello Lineare fornisce una soluzione robusta, più sicura e più semplice (Rasoio di Occam).

5.5. Analisi della Curva ROC

Per valutare ulteriormente la capacità diagnostica dei nostri modelli, abbiamo analizzato le curve Receiver Operating Characteristic (ROC), che tracciano il True Positive Rate (Sensibilità) rispetto al False Positive Rate (1 - Specificità) a varie impostazioni di soglia.




Figura 17: Confronto delle Curve ROC. L'Area Sotto la Curva (AUC) funge da singola misura scalare delle prestazioni. I modelli SVM (in particolare Lineare e RBF) mostrano un'AUC superiore rispetto al singolo Albero di Decisione.

Il confronto visivo conferma che i modelli SVM forniscono una classificazione più robusta delle probabilità di Malignità, raggiungendo un'AUC più vicina a 1.0. Ciò indica una maggiore probabilità che il modello classifichi un'istanza maligna scelta casualmente come superiore rispetto a una benigna.

6. Analisi Comparativa: Albero di Decisione vs SVM

Dopo aver ottimizzato entrambe le famiglie di modelli, abbiamo condotto un confronto finale tra la migliore configurazione dell'Albero di Decisione (Potato con $\alpha = 0.0045$) e la Support Vector Machine (Kernel Lineare).

6.1. Metriche Finali Consolidate

La Tabella 6 riassume i punteggi finali ottenuti sul set di test indipendente, mostrando le prestazioni specifiche sulla classe Maligna.

Metrica	Albero di Decisione (Potato)	SVM (Kernel Lineare)
Accuratezza	95.61%	98.25%
Precision (Maligno)	97.44%	100%
Recall (Maligno)	90.48%	95.24%
F1-Score (Maligno)	93.83%	97.56%

Tabella 6: Riepilogo del confronto delle prestazioni del modello sul set di test.

6.2. Credibilità e Significatività Statistica

Per valutare rigorosamente i modelli sul Test Set indipendente ($N = 171$), abbiamo calcolato gli **Intervalli di Confidenza Binomiali al 95%** per stimare il probabile intervallo di prestazioni su dati non visti.

Modello	Accuratezza del Test	IC 95% ($\pm$)
Albero di Decisione (Potato)	95.61%	3.07%
SVM (Kernel Lineare)	98.25%	1.97%

Tabella 7: Prestazioni del modello sul Test Set con Intervalli di Confidenza al 95%.

L'intervallo di confidenza più stretto per la SVM (1.97% vs 3.07%) ne conferma la superiorità e l'affidabilità come strumento diagnostico.

6.3. Robustezza e Generalizzabilità del Modello

Le elevate prestazioni raggiunte dalla SVM Lineare (accuratezza del 98.25% e precision del 100%) sono state ulteriormente analizzate per escludere l'overfitting.

La coerenza tra l'accuratezza della **Cross-Validation** (media del 97.15% su 10 fold) e il risultato finale del **Test Set** (98.25%) dimostra che il modello generalizza efficacemente a dati non visti. Il raggiungimento del **100% di Precision** per la classe Maligna significa una totale assenza di Falsi Positivi nel set di test, una caratteristica ideale per i sistemi di supporto diagnostico in cui dovrebbero essere evitate biopsie non necessarie.

Questa robustezza è attribuita a due fattori:

- **Pulizia delle Caratteristiche:** L'uso di 10 componenti PCA (che spiegano il 95.14% della varianza) ha agito efficacemente come filtro del rumore, rimuovendo le fluttuazioni non informative dalle 30 dimensioni originali.
- **Regolarizzazione Intrinseca:** La formulazione della SVM (con $C = 1.0$) massimizza intrinsecamente il margine tra le classi, impedendo al confine decisionale di essere eccessivamente sensibile a specifici campioni di addestramento.

Analisi del Compromesso (Trade-off)

- **Affidabilità Statistica:** I concetti teorici della **Macro-averaging** sono stati applicati vista la natura bilanciata delle classi target. Il **Paired t-test** conferma che la SVM non è solo migliore su questo specifico set di test, ma è uno stimatore più credibile in generale per questo compito diagnostico.
- **Soglie Sensibili ai Costi:** Come discusso nella lezione sui "Problemi di Valutazione", la curva ROC consente ai medici di regolare la soglia di classificazione. In questo contesto clinico, dare priorità al **Recall** (minimizzando i Falsi Negativi) è fondamentale, favorendo la SVM Lineare che mantiene un'elevata precision anche a soglie progettate per la sicurezza.

7. Conclusioni

Questa ricerca ha sviluppato con successo un robusto sistema di supporto alle decisioni per la classificazione del tumore al seno, soddisfacendo gli obiettivi iniziali delineati nell'abstract.

Impiegando una strategia unificata di riduzione della dimensionalità tramite PCA (10 componenti), abbiamo garantito un confronto rigoroso ed equo tra due distinti paradigmi di machine learning. Dalla nostra campagna sperimentale sono emersi i seguenti spunti chiave:

- **Selezione del Classificatore Ottimale:** La **SVM con Kernel Lineare** è emersa come il candidato superiore per la distribuzione clinica, raggiungendo un'accuratezza del **98.25%** e una **Precision perfetta del 100%** sul set di test. La sua capacità di minimizzare i Falsi Negativi (**Recall del 95.24%**) risponde direttamente al primario requisito di sicurezza medica del progetto.
- **Efficienza della Separazione Lineare:** I dati suggeriscono che le caratteristiche biometriche derivate dai nuclei cellulari, una volta elaborate attraverso un filtro di varianza cumulata (95.14%), siano sufficientemente separabili in uno spazio latente lineare, rendendo superflue e meno stabili le costose trasformazioni del kernel non lineare.
- **Il Valore dell'Interpretabilità:** Sebbene l'Albero di Decisione abbia mostrato metriche complessive inferiori, il suo ruolo rimane significativo. Il processo di potatura ha evidenziato con successo una logica decisionale semplificata basata su soglie critiche (es. *worst area* e *concave points*), offrendo un'alternativa "white-box" che i medici possono facilmente verificare.
- **Robustezza Statistica:** La coerenza tra i risultati della Cross-Validation e le prestazioni del set di test, insieme a stretti intervalli di confidenza al 95%, conferma che i risultati sono credibili e non frutto di overfitting.

In conclusione, mentre la SVM Lineare fornisce l'eccellenza numerica richiesta per l'aiuto diagnostico automatizzato, l'uso combinato di entrambi i modelli fornisce una comprensione più completa del dataset, colmando il divario tra la previsione ad alte prestazioni e il ragionamento intelligibile dall'uomo.